

语音情绪识别中的验证说话人曝光与检查点选择

作者: Tian Xie

单位: University of Toronto

电子邮箱: tianjack.xie@mail.utoronto.ca

摘要

验证集的说话人隔离与检查点选择经常被放在一起讨论，但验证乐观偏差与共同测试集上的表现是不同的量。我们沿相同的 WavLM 训练轨迹，比较已见和未见说话人验证，并分别使用交叉熵（CE）或无权平均召回率（UAR）选择检查点。冻结协议覆盖三个原生情绪识别任务，共 360 条主要训练轨迹和 24 次对照拟合。使用 CE 选择时，已见说话人验证所选模型的共同外测 UAR 在 CREMA-D 上高出 0.935 个百分点，在 SUBESCO 上高出 2.247 个百分点；对应的 CE 相对 UAR 交互效应分别为 0.937 和 2.560 个百分点。这四项对比在六项 Holm 校正后仍有统计证据。RAVDESS 的估计仍不确定。使用 UAR 选择时，已见减未见的描述性差值接近零，但不构成等效性证据。完整的 15 轮曲线和整组对照限制了机制解释。结果支持这一固定程序下依赖选择准则的效果，不支持说话人独立验证具有普遍优势的主张。

关键词: 语音情绪识别; 说话人独立性; 检查点选择; 验证; 评估

1 引言

语音情绪识别（SER）经常在未参与训练的说话人上评估。说话人隔离已是受到重视的评估问题。SERAB 和 Antoniou 等研究明确分离训练、验证与测试说话人 [1][2]。更一般地，优化有限样本上的选择准则会影响后续性能评估 [3]。然而，验证成绩的差异与所选模型在同一个未见说话人测试集上的性能差异，是不同的量。更大的验证-测试差距，本身不能证明相应选择规则产生了更差的测试模型。

既有 SER 研究已经跨数据集、模型或重复运行比较随机划分与演员独立评估 [4][5][6]；在说话人与文本条件之间匹配训练录音数也已有先例 [7]。这些比较说明评估协议与研究结论有关，但有些比较在改变关注的划分边界时，也改变训练或测试成员。本文因此聚焦一个具体的检查点选择问题：在同一训练轨迹上，分别用已见或未见说话人验证，按 CE 或 UAR 选模，再在同一个说话人独立外测集上比较。固定候选轨迹，使轨迹内的比较不受不同训练运行之间差异的影响。两个验证组仍由不同的人组成，因此这里比较的是完整选模规则，而非孤立的声纹机制。

本设计承接本项目此前对已接触语料的分析 [8]。在新的拟合开始前，固定一个模型配置、全部 15 个候选轮次和分析规则。主要量是两种 CE 规则在共同外测上的差异，以及该差异与 CE/UAR 选择准则的交互。三个原生任务与全部六项预定检验均予保留。完整轨迹和固定末轮的训练人群互换提供描述性背景，不增加假设检验，也不决定哪些结果值得报告。

2 实验设计

2.1 共享训练轨迹的检查点选择协议

本协议规定 360 条主要训练轨迹，即每个语料 24 个 draw、每个 draw 五个外层折，另加 24 次 CREMA-D 配对对照拟合。检查点规则共享训练轨迹和说话人独立外测集。CREMA-D、SUBESCO、RAVDESS 分别保留原生六类、七类、八类任务，以及 91、20、24 名说话人 [9][10][11]。这些语料已有研究接触历史。协议采用执行前的私有源码与计划冻结，不是公开预注册。新 draw 不构成此前完全未接触的数据。

每个 draw 按记录的性别分层，以元数据哈希把说话人分为五个外层折；每人恰好属于一个外测折。在该折之外选择互不重叠的开发组 A、B，各组性别平衡，在选定文本上完整覆盖原生类别。所有 query 组共享文本，且这些文本与训练文本不相交（表 1）；未选中的说话人不使用。冻结的代表录音规则为 CREMA-D 优先 MD、否则 XX，SUBESCO 使用 T1，RAVDESS 使用正常强度 R1，不用其他 take 补位。外测 query 保留可用代表录音，同时要求每名外测说话人均有全部原生类别。开发容量不足触发元数据检查失败，不能依据模型结果重新抽样。

表 1. 每个 context 的预定配置。A、B 等大且各自性别平衡；数量指不同的说话人或录音。

语料	类数	A/B 人数	外测人数	训练/query 文本数	训练录音数	各组 query 录音数
CREMA-D	6	24/24	17/19	4/2	576	288
SUBESCO	7	8/8	4	4/2	224	112
RAVDESS	8	8/8	4/6	1/1	64	64

训练/query 列表示两者各自的文本数；最后一列表示 A、B 每组的 query 录音数。外测 query 使用 CREMA-D 的可用代表录音、SUBESCO 的 56 条录音，或 RAVDESS 的 32/48 条录音。斜线分隔的外测数量表示不同折可能具有的规模。

主要轨迹使用 A 组训练。WavLM base-plus [12] 在最后一层特征的时间均值之上接原生类别数的线性分类头，只训练最高四个 Transformer 层与分类头。固定配置沿用此前研究中的 cfg3：AdamW，编码器/分类头学习率为 5×10^{-5} / 10^{-3} ，weight decay 为 0.01，batch size 为 16，使用不加类别权重的交叉熵。训练完整遍历训练集 15 轮，不提前停止、不搜索超参数。训练使用 FP16 autocast 与 FP32 参数；评估使用 FP32。单声道 16 kHz 音频按 30 dB 阈值修剪静音；训练使用三秒裁剪或补零，评估取前至多十秒。

A query 提供已见说话人验证，B query 提供未见说话人验证。全部 15 轮记录 A、B、outer 的 logits。四条规则分别在 A 或 B 上最小化平均交叉熵，或最大化 UAR；精确并列取最早轮次，以有理数召回计算保留 UAR 的精确并列。UAR 是整个 query 组全部原生类别的宏平均召回率，不是逐说话人 UAR 的平均。每组独立按固定排序组成 batch size 为 16 的批次，跨轮次

与配对模型保持相同。外测音频不能参与验证批次的补零。池化没有长度 mask：这里固定了 padding 上下文，但 padding 效应仍然存在。

令 $T(g, q)$ 为验证组 g （已见 s 、未见 u ）按准则 q 选定轮次的外测 UAR，单位为百分比。每个 context 的对比为：

$$\delta_q = T(s, q) - T(u, q), q \in \{CE, UAR\}$$

$$J = \delta_{CE} - \delta_{UAR}$$

这些是单位为百分点（pp）的外测 UAR 差异，不是损失差，也不是验证乐观偏差（V-T）的差异。它们比较选择规则，不识别某个唯一的说话人机制。四条规则复用一条轨迹，不需要四次训练。

每个语料内，先等权平均一个 draw 的折扣效应，再以 24 个完整 draw 的效应进行双侧单样本 t 推断（ $df=23$ ）。六项检验族为三个语料各自的 (δ_{CE}, J) ，在 0.05 水平使用 Holm 控制，并给出逐项 95% t 区间。零样本方差导致未定义的检验保留 NA，仍占据其检验族位置。绝对 UAR 和 δ_{UAR} 仅作描述。1 pp 是实际幅度参照，不是等效界值；本研究不做等效性检验。推断条件于有限语料与训练程序；折、录音、重复出现的人物和规则不是额外独立重复。各语料原生任务不同，不能据此合并作总体推断或声称语言效应。

CREMA-D 的 fold 0 每个 draw 增加一个 B 训练的模型，与 A 共享初始权重、匹配的随机日程以及性别/文本/类别训练槽预算。每个性别内，槽还匹配说话人顺位、take 和强度。B 完整训练 15 轮，只记录末轮 query，不选择检查点。令 Q_A 、 Q_B 为相应整个 query 组的 UAR，单位为百分比：

$$E = 0.5 \times \{[Q_A(M_{A15}) - Q_A(M_{B15})] + [Q_B(M_{B15}) - Q_B(M_{A15})]\}$$

24 对结果及其均值仅作描述。这里替换的是整个训练人群，不是单个说话人；相同 query 也用于选择主要 A 轨迹的检查点。

四次技术 pilot 不计入 384 次拟合。评分要求完成源码、产物、检查点与 ledger 核验。预定描述保留选中轮次的分布及一致性、全部 15 轮的外测曲线、末轮 UAR、8-10 轮相对 14-15 轮的均值 UAR 差，以及相对各轨迹最高外测 UAR 的差距。该 oracle 不选择保留的检查点，也不延长训练。完整处理、随机化与核验细节随冻结协议提供。

3 结果

3.1 预定共同外测效应

表 2 报告完整的六项检验族。已见 CE 选择相对于未见 CE 选择，在 CREMA-D 上高出 0.935 pp，在 SUBESCO 上高出 2.247 pp；两者的逐项区间均不含零，Holm 调整后的 p 分别为 0.0264 和 0.0083。正向交互效应 0.937 和 2.560 pp 在 Holm 校正后也仍有统计证据。因此，这两个任务的已见-未见选择对比依赖于选择准则。CREMA-D 的 CE 点估计低于 1 pp 参照，SUBESCO 的高于该参照，但两者的区间均包含 1 pp。这些检验不能确立效应大于该参照值。

表 2。六项预定共同外测效应，单位为 UAR 百分点 (pp)。区间为 draw 层面的逐项 95% t 区间；p 为双侧原始值，以及保留六项家族的 Holm 调整值。

语料	对比	均值 (pp)	逐项 95% CI (pp)	原始 p	Holm p
CREMA-D	δ CE	0.935	[0.287, 1.583]	0.0066	0.0264
CREMA-D	J	0.937	[0.210, 1.663]	0.0138	0.0413
SUBESCO	δ CE	2.247	[0.945, 3.549]	0.0016	0.0083
SUBESCO	J	2.560	[1.103, 4.016]	0.0014	0.0083
RAVDESS	δ CE	0.486	[-0.198, 1.170]	0.1549	0.3098
RAVDESS	J	0.469	[-0.633, 1.570]	0.3877	0.3877

RAVDESS 得到 δ CE=0.486 pp、J=0.469 pp，两者区间均跨零。这是尚无定论的证据，不是第三个得到确认的效应，也不是等效性证据。没有删除任何语料，也没有在查看结果后增加拟合或检验。

3.2 绝对性能与选模行为

表 3 保留全部四种规则和固定第 15 轮。在 UAR 选择下，已见减未见的描述性差值依次为 -0.002、-0.313 和 +0.017 pp。这些较小的均值不构成等效性证据。在 CREMA-D 和 SUBESCO 上，UAR 所选模型的平均外测 UAR 高于 CE 所选模型；RAVDESS 的排序相反。这些任务内部的描述性排序不支持存在普遍最优的准则。

表 3。四种检查点规则及固定第 15 轮的描述性外测 UAR (%)，以及单位为 pp 的 δ UAR。先等权平均五折，再等权平均 24 个 draw。

语料	已见 CE (%)	未见 CE (%)	已见 UAR (%)	未见 UAR (%)	第 15 轮 (%)	δ UAR (pp)
CREMA-D	56.253	55.318	57.154	57.155	53.715	-0.002
SUBESCO	47.113	44.866	47.426	47.738	47.292	-0.313
RAVDESS	33.941	33.455	32.943	32.925	32.821	0.017

按 CREMA-D、SUBESCO、RAVDESS 的顺序，已见/未见 CE 选择的平均轮次分别为 6.71/5.89、10.71/7.92 和 14.35/13.86；UAR 选择的平均轮次分别为 10.53/10.09、12.54/11.98 和 13.66/13.48。CE 轮次一致率分别为 58.3%、26.7% 和 76.7%；UAR 一致率分别为 37.5%、27.5% 和 42.5%。因此，相近的汇总 UAR 对比不一定意味着选中了相同轮次。完整分布和相对 oracle 的差距随研究工件提供。CREMA-D 上，已见/未见 CE 选择距外测 oracle 的平均差距为

2.34/3.27 pp, 两种 UAR 规则均约为 1.44 pp, 第 15 轮为 4.88 pp; 这些是相对于逐轨迹外测最大值的描述性差距, 不是可实现的选模保证。

3.3 完整轨迹与整组互换




图 1。三个原生任务的全部 15 轮曲线。浅灰细线表示每个语料的 120 条单独外测轨迹；三条粗线分别等权平均 120 个主要 context 的已见验证、未见验证和外测成绩。不作平滑，不额外添加曲线不确定性带。

图 1 显示 CREMA-D 进入平台期，而 SUBESCO 和 RAVDESS 的平均外测表现持续改善。预定的第 8-10 轮平均 UAR 减去第 14-15 轮平均 UAR，依次为 +0.208、-2.894 和 -8.977 pp。这些曲线不支持统一的训练后期崩溃解释。在 RAVDESS 的 120 条轨迹中，已见 CE 有 72 条选择第 15 轮，未见 CE 有 62 条选择第 15 轮；固定训练截止轮次限制了对更晚行为的解释。

CREMA-D 训练人群互换的 24 对平均值为 $E=2.828$ pp。全部配对值，包括其中为负的一对，均保留在研究工件中。这与如下平均优势相容：在训练槽匹配时，模型在来自自身训练说话人组的 query 上表现更好。它既不隔离单个说话人的因果作用，也不能确立 CE 和 UAR 为何选择不同检查点。

4 讨论

主要发现是共同外测上的选模行为依赖于选择准则。使用说话人隔离的验证集仍是评估泛化表现的既有做法，但这一理由并不保证其 CE 所选检查点在同一外测集上的表现优于已见 CE 规则所选检查点。反过来，这些结果也不能支持用已见说话人成绩替代说话人独立的评估报告：模型选择与所报告的评估回答不同的问题。CE 衡量预测概率的质量，UAR 则取决于类别决策；这种区别提供了一种值得进一步研究的可能解释，不是已经检验的校准机制。

本项目此前的研究 [8] 有助于区分这些估计量。N14R2 发现验证乐观偏差 $\Delta(V-T)$ 相差 1.419 pp，但内层程序同时改变了拟合成员。DUAL 保持共同拟合轨迹，发现 2.706 pp 的乐观偏差对比，同时所选模型的外测成绩差为正。这些量不是本文的 δ_q 。后续检查点诊断促成本次固定配置研究；它们是对既有预测的事后使用，不是独立重复验证。共享语料和此前的拟合次数不能扩大当前推断样本量。

4.1 比较范围与数据构建启示

估计条件于有限的表演语音语料、一个部分微调的编码器和固定训练轮次。任务在原生类别、说话人数、文本和拟合规模上存在差异，因此既不能识别语言效应，也不能公平排列语料难度。已见与未见验证组的人物和录音分布也不同，不能作孤立的声纹解释。固定角色批次保留 padding 上下文，没有消除其影响。整组互换的 query 同时参与主要模型的选择，不是全局未用过的盲测。

相关数据构建研究回答的是更窄的问题。在固定录音数下，增加说话人数也减少了每人的文本覆盖；在 288/576 条录音预算下，CNN 在未见文本上的增益分别为 1.08/2.16 pp，估计的是这一联合取舍。另一个声纹覆盖策略相对于均匀选择，CNN 差值为 -0.109 pp（条件性的配对说话人 bootstrap 95% 区间 $[-0.715, 0.509]$ ），这不能证明等效，也不能证明覆盖策略普遍无用。这些研究及完整结果保留在研究工件中，不合并作为当前终点的确认性证据。合成语音训练未获准入：技术生成和未完成的人类评估没有满足质量协议。尚未证明存在能消除已见-未见差距的数据集。

4.2 执行与可获得性

全部 384 次正式拟合在一张 RTX 5070 上完成，没有训练重试；四次 pilot 不计入正式拟合。单元墙钟时间累计 4.78 小时，包括规定的评估与保存。研究工件记录了 110,160 次更新尝试和 44 次 AMP 跳过。完整源码、产物、检查点和 ledger 核验，以及独立数值重放均已通过。在修正一项有记录的启动器环境错误后，对四个预先指定单元进行新进程回载，30 个“保存状态-query 组”比较全部精确复现。这项有限检查不是独立重新训练。便携预测包解压后的数值重放已通过；包中不含音频、基础模型权重和检查点。研究工件在撰稿时限制访问。私有冻结建立的是版本历史，不是公开预注册。

5 结论

在共同 WavLM 轨迹和共同外测集上，基于 CE 的已见说话人选择在 CREMA-D 和 SUBESCO 上表现更好，并有证据表明曝光选择对比会在采用 UAR 准则时改变。RAVDESS 仍不确定；这些运行的完整曲线不支持统一的训练后期崩溃解释。贡献是一个呈现准则依赖性的受控选择规则比较，不是普遍适用的验证处方，也没有识别说话人或语言机制。

致谢与 AI 使用披露

Anthropic Claude 协助了原始实现、起草和科学审阅。OpenAI Codex 协助了实验设计、实现与执行、文献及分析核查，以及所有论文章节和表格的起草与修订。这些系统不是作者；署名人类作者负责审阅证据并批准投稿。实验使用既有数据集，没有新增采集受试者数据。

参考文献

以下条目与英文稿按首次引用次序一致；保留英文题名便于查找原文。

- [1] N. Scheidwasser-Clow, M. Kegler, P. Beckmann, and M. Cernak, “SERAB: A multi-lingual benchmark for speech emotion recognition,” in Proc. ICASSP, 2022, pp. 7697–7701, doi: 10.1109/ICASSP43922.2022.9747348.
- [2] N. Antoniou, A. Katsamanis, T. Giannakopoulos, and S. Narayanan, “Designing and evaluating speech emotion recognition systems: A reality check case study with IEMOCAP,” in Proc. ICASSP, 2023, pp. 1–5, doi: 10.1109/ICASSP49357.2023.10096808.
- [3] G. C. Cawley and N. L. C. Talbot, “On over-fitting in model selection and subsequent selection bias in performance evaluation,” *Journal of Machine Learning Research*, vol. 11, no. 70, pp. 2079–2107, 2010.
- [4] E. Ibrahim, M. E. Ghoraba, and A. E. Ghoraba, “Multimodal emotion recognition using hybrid deep feature fusion under speaker-independent evaluation,” *Scientific Reports*, vol. 16, Art. 19584, 2026, doi: 10.1038/s41598-026-58836-w.
- [5] M. Zielonka et al., “Recognition of emotions in speech using convolutional neural networks on different datasets,” *Electronics*, vol. 11, no. 22, Art. 3831, 2022, doi: 10.3390/electronics11223831.
- [6] P. Kumari et al., “Hybrid CNN-embedding fusion with MFCC-SVM for speech emotion recognition: Random vs actor-wise evaluation on CREMA-D,” *PLOS One*, vol. 21, no. 8, Art. e0355238, 2026, doi: 10.1371/journal.pone.0355238.
- [7] B. T. Atmaja and A. Sasou, “Effect of different splitting criteria on the performance of speech emotion recognition,” in Proc. TENCON, 2021, pp. 760–764, doi: 10.1109/TENCON54134.2021.9707265.
- [8] T. Xie, “SER: Speaker-validation studies and the completed checkpoint-selection program,” GitHub repository, 2026. [Online; access restricted at manuscript preparation]. <https://github.com/DeerNeverStop/SER>. Frozen scientific commit: 976297d; completed evidence: SER26-final-program-complete-20260907. Earlier N14R2, DUAL, recording-budget and coverage results are retained with their separate protocols.
- [9] H. Cao, D. G. Cooper, M. K. Keutmann, R. C. Gur, A. Nenkova, and R. Verma, “CREMA-D: Crowd-sourced emotional multimodal actors dataset,” *IEEE Trans. Affective Computing*, vol. 5, no. 4, pp. 377–390, 2014, doi: 10.1109/TAFFC.2014.2336244.

- [10] S. Sultana, M. S. Rahman, M. R. Selim, and M. Z. Iqbal, “SUST Bangla Emotional Speech Corpus (SUBESCO): An audio-only emotional speech corpus for Bangla,” PLOS ONE, vol. 16, no. 4, Art. e0250173, 2021, doi: 10.1371/journal.pone.0250173.
- [11] S. R. Livingstone and F. A. Russo, “The Ryerson Audio-Visual Database of Emotional Speech and Song (RAVDESS): A dynamic, multimodal set of facial and vocal expressions in North American English,” PLOS ONE, vol. 13, no. 5, Art. e0196391, 2018, doi: 10.1371/journal.pone.0196391.
- [12] S. Chen et al., “WavLM: Large-scale self-supervised pre-training for full stack speech processing,” IEEE J. Sel. Topics Signal Process., vol. 16, no. 6, pp. 1505–1518, 2022, doi: 10.1109/JSTSP.2022.3188113.