

验证集里是谁，会改变最后选出的情绪识别模型吗？

一、先说发现：训练过程相同，最后选哪一轮仍然重要

这篇论文发现：即使训练过程和陌生说话人的测试集完全相同，改变验证人群、选模指标或可选的训练轮数，最终选出的模型及其测试成绩仍会变化。因此，只写“测试说话人没有出现在训练中”，还不足以完整说明一次语音情绪识别评估。

本解读对应2026年9月9日英文修订稿，面向希望理解研究问题、实验方法与结果的读者，不是逐句翻译。所有数字来自已经完成并核验的原研究及补充实验；解释性文字没有增加训练、统计检验或新的研究结论。

可以把每轮训练后的模型看成一张“成长快照”。训练完成后，我们面对同一本包含15或45张快照的相册，让四套规则分别挑选最满意的一张。它们依据的验证录音和评价指标不同，但候选相册相同，最终接受的陌生说话人测试也相同。论文研究的是这种**选片规则**会不会改变最后的成绩。

四套规则不是让模型各自重新练习一遍。它们共享已经训练好的候选模型，因此可以排除“四次训练本来就有随机差异”这一解释。主轨迹每轮会计算并保存外测预测，但外测成绩不参与选点或决定训练长度：它负责评价，不负责挑照片。

最清楚的新结果有两部分。第一，换成第二个骨干模型HuBERT后，按交叉熵选点时，熟悉说话人的验证集在三库上选出的模型，外测平均高出1.576、4.018、1.398个百分点；其中两库还支持“这种人群差依赖选模指标”。第二，RAVDESS上的WavLM从15轮候选扩展到45轮后，交叉熵人群差增加2.257个百分点。新实验预定的十项检验有六项通过共同校正，其余四项同样保留。

这不是“陌生验证集一定不好”或“以后应当总用熟人选模型”。不同模型、语料和窗口有不同排名。研究的实际提醒是：**最后报出的性能，也取决于研究者怎样从训练轨迹中挑选模型。**

二、怎么比较：共同训练、四种选法、共同陌生测试

每个实验条件先划出互不重叠的开发说话人组A、B，以及外层测试说话人。主实验只用A组训练；A组另一批文本的录音是“已见说话人验证”，B组对应文本的录音是“未见说话人验证”。“已见”指模型在训练中接触过这个人的声音，不是重复使用同一条训练录音。

四种选法为：A组交叉熵最低、B组交叉熵最低、A组UAR最高、B组UAR最高。指标精确并列时取最早一轮。四个结果都交给同一个陌生说话人测试集。验证和测试使用相同的查询文本，查询文本与训练文本分开，减少文本条件不同造成的解释困难。

数据库	原生情绪类数	A/B人数	每折外测人数	训练/查询文本数	训练录音数	每个开发查询组录音数
CREMA-D	6	24/24	17或19	4/2	576	288
SUBESCO	7	8/8	4	4/2	224	112
RAVDESS	8	8/8	4或6	1/1	64	64

三个数据库分别保留91、20、24名说话人，A/B组按记录的性别均衡。外测录音数随数据库及人数而定：SUBESCO为56，RAVDESS为32或48；CREMA-D保留符合要求的可用代表录音，并要求每个外测说话人包含所有原生情绪类。不能把三库不同类数、文本或录音条件的差异单独解释为语言效应。

原研究完成384次正式拟合：360条WavLM主轨迹，加24条CREMA-D整组角色交换对照。**后者只保留第15轮的报告预测**，不进入原三库主结果的均值。补充实验完成720次：HuBERT三库共360条；新WavLM三库共360条，其中SUBESCO、RAVDESS训练45轮，CREMA-D训练15轮。45轮轨迹本身的前15轮构成其配对短窗口，不能换成旧研究的WavLM结果。

所以本文使用1,104次正式拟合，但它们不是1,104个独立样本；原研究4次、补充实验8次技术试跑不计入正式结果。所有主轨迹训练完规定轮数，不做动态提前停止，只微调编码器最上面四层及分类头。每个查询角色单独采用固定批次，避免外测录音长度改变验证批次的补零情况；平均池化仍没有长度掩码，这一限制没有被固定批次消除。

三、先认清数字：UAR、百分点、人群差与检验

交叉熵（CE）是根据模型给正确类别分配的概率计算的损失：正确类别的概率越高，这项损失越低，因此CE越低越好。**UAR**先计算每个情绪类别的召回率，再对类别等权平均，越高越好。例如某一大类样本很多，也不会仅凭数量主导UAR。文中的UAR按完整查询角色计算，不是先给每个人算分再平均。

CE和UAR在这里首先是“选哪一轮”的依据。最终用来比较四套选法的成绩，统一是陌生外测的UAR。例如55%提高到57%，是提高**2个百分点（pp）**，不是把提高幅度称为2%。下面所有人群差和交互量都用pp，绝不是交叉熵损失的差。

名称	计算方式	回答的问题
CE人群差（ δCE ）	已见CE所选模型的外测UAR - 未见CE所选模型的外测UAR	按CE选点时，两种验证人群选出的模型相差多少？
UAR人群差（ δUAR ）	已见UAR所选模型的外测UAR - 未见UAR所选模型的外测UAR	按UAR选点时，人群差是多少？
指标交互J	$\delta CE - \delta UAR$	人群差是否随选模指标而变？
窗口变化L_CE	45轮窗口的 δCE - 15轮窗口的 δCE	扩大候选集后，CE人群差是否变化？
窗口变化L_J	45轮窗口的J - 15轮窗口的J	指标交互是否随窗口变化？

正的人群差表示：在相同陌生外测上，已见规则选出的模型更好。它不是“验证分数减测试分数”的乐观偏差，也不是声纹记忆程度。正J说明CE下的人群差比UAR下更大；它不等于CE或UAR在绝对成绩上必然更优。

每个数据库做24次预定重抽划分，每次包含五个外层折。统计时先把五折效果等权平均，再用24个draw均值计算双侧t检验与95%区间，自由度为23。**这24次不是24批全新独立人群**：相同的有限说话人会重复出现，区间描述的是这些语料和重抽程序下的条件性不确定性。

同时提出多个问题，会增加偶然出现“小p值”的机会。因此原六项检验共同用Holm6校正；补充实验十项共同用Holm10，两组保持分开。下表“通过”指校正后的p小于0.05。95%区间是逐项区间，不是同时区间；区间不跨零也可能没通过Holm。未通过不等于已经证明没有效应，更不等于等效。

四、原研究和第二骨干：支持在哪里，不确定在哪里？

下面保留全部原六项和HuBERT六项。均值与区间单位为pp；“原p”是双侧未校正p，“校正p”属于表注明明的家族。

原研究：WavLM、15轮窗口，六项共同Holm6

数据库	指标	均值	95%区间	原p	校正p
CREMA-D	CE人群差	0.935	[0.287, 1.583]	0.0066	0.0264
CREMA-D	指标交互J	0.937	[0.210, 1.663]	0.0138	0.0413
SUBESCO	CE人群差	2.247	[0.945, 3.549]	0.0016	0.0083
SUBESCO	指标交互J	2.560	[1.103, 4.016]	0.0014	0.0083
RAVDESS	CE人群差	0.486	[-0.198, 1.170]	0.1549	0.3098
RAVDESS	指标交互J	0.469	[-0.633, 1.570]	0.3877	0.3877

CREMA-D和SUBESCO的两项均通过校正：已见CE选点的外测均值更高，而且这一人群差依赖所用指标。RAVDESS两项仍不确定，没有因为结果不支持就把它删掉。这个结论也没有推广成“三库都存在相同强度的效应”。

补充实验：HuBERT、15轮窗口，以下六项属于共同Holm10

数据库	指标	均值	95%区间	原p	校正p
CREMA-D	CE人群差	1.576	[1.000, 2.153]	9.28×10^{-6}	7.43×10^{-5}
CREMA-D	指标交互J	1.296	[0.499, 2.093]	0.0027	0.0161
SUBESCO	CE人群差	4.018	[2.835, 5.201]	3.67×10^{-7}	3.67×10^{-6}
SUBESCO	指标交互J	3.616	[2.332, 4.900]	6.15×10^{-6}	5.54×10^{-5}
RAVDESS	CE人群差	1.398	[0.425, 2.370]	0.0068	0.0340
RAVDESS	指标交互J	0.703	[-0.510, 1.917]	0.2428	0.4857

换成HuBERT后，三库的CE人群差都通过校正；但指标交互仍只有CREMA-D和SUBESCO得到支持。于是，第二骨干加强的是这两库的“指标依赖”证据，而不是证明所有语料都有交互。HuBERT表和下一节四项窗口检验一起校正，不能把这六行单独重新校正成更小的家族。

还要区分“换模型后某项显著了”与“模型之间的效果差显著”：前者不能自动推出后者。本文保留同平台配对骨干差的描述区间，但没有把两模型的显著性标签直接当成骨干交互检验。

五、训练满45轮后，扩大可选范围会发生什么？


补充实验在SUBESCO和RAVDESS上训练完整45轮WavLM，然后分别只允许从前15轮、或全部45轮中选模型。这是在同一条长轨迹上扩大候选集合，不是两次独立训练，也不是发现验证分数不好就现场决定多练30轮。

预定的四项窗口检验：与上一节HuBERT六项共同Holm10

数据库	指标	均值	95%区间	原p	校正p
SUBESCO	窗口变化 L_CE	0.283	[-0.009, 0.574]	0.0567	0.1702
SUBESCO	窗口变化 L_J	0.268	[-0.761, 1.297]	0.5954	0.5954
RAVDESS	窗口变化 L_CE	2.257	[1.294, 3.220]	6.82×10^{-5}	4.77×10^{-4}
RAVDESS	窗口变化 L_J	1.849	[0.343, 3.355]	0.0183	0.0731

RAVDESS的CE人群差从0.217变为2.474 pp，其增加量通过校正。但这不是“越练测试越崩”：已见CE所选模型的外测从34.983%升到42.700%，未见CE也从34.766%升到40.226%。双方都进步，进步幅度不同，所以差距扩大。

RAVDESS的L_J区间虽然不跨零，校正p仍为0.0731，不能称为校正后得到支持。SUBESCO两项都未通过，尤其L_J区间从-0.761延伸到1.297，不能据此证明窗口不影响它或已经收敛。



事后候选窗口图：蓝色实线为CE、橙色虚线为UAR；纵轴是已见减未见所选模型的外测UAR差。阴影按五折先平均、再24个draw计算逐点95%t区间，不是同时置信带。所有轨迹均完整训练45轮。

图是在结果完成后补充的1至45轮逐窗口描述，没有增加训练或确认性检验。SUBESCO观测到的CE差在约20轮后变化较小，RAVDESS在晚窗口变大；这不能证明总体存在某个阈值或饱和点。**正式窗口推断只对应上表四行，不能看图后挑一个更有利的窗口重新宣布显著。**

六、差距之外，还要看绝对成绩和最简单的基线

下表保留全部11个设置。前五个成绩列都是共同陌生外测的UAR百分数；“已/未”指验证说话人是否进入训练，“末轮”不按验证指标选点。最后一列为UAR人群差，单位pp。数字先用完整精度计算再保留三位，不能要求打印出的两格相减总与差值末位一致。

原研究：全部三个设置

数据库	骨干	轮数	已见CE	未见CE	已见UAR	未见UAR	末轮	δ UAR
CREMA-D	WavLM	15	56.253	55.318	57.154	57.155	53.715	-0.002
SUBESCO	WavLM	15	47.113	44.866	47.426	47.738	47.292	-0.313
RAVDESS	WavLM	15	33.941	33.455	32.943	32.925	32.821	0.017

补充实验：全部八个设置

数据库	骨干	轮数	已见CE	未见CE	已见UAR	未见UAR	末轮	δ UAR
CREMA-D	WavLM	15	55.121	54.103	56.541	56.430	53.240	0.111
SUBESCO	WavLM	15	48.110	45.774	47.946	47.470	47.009	0.476
SUBESCO	WavLM	45	48.393	45.774	49.613	49.122	48.839	0.491
RAVDESS	WavLM	15	34.983	34.766	34.028	33.325	34.141	0.703
RAVDESS	WavLM	45	42.700	40.226	43.516	42.405	42.491	1.111
CREMA-D	HuBERT	15	57.002	55.426	58.783	58.503	56.446	0.280
SUBESCO	HuBERT	15	48.616	44.598	49.836	49.435	49.048	0.402
RAVDESS	HuBERT	15	42.066	40.668	41.450	40.755	41.615	0.694

新实验四规则均值范围为33.325%至58.783%。八个设置里，UAR在两种验证人群上都优于CE的有五个；SUBESCO WavLM15和HuBERT RAVDESS是两侧方向相反，RAVDESS WavLM15则两侧CE都更好。这些是均值排名，不是另加八次显著性检验。

固定末轮也提供了必要参照。CREMA-D上，HuBERT末轮56.446%介于两种CE选点成绩之间；WavLM末轮53.240%却低于两种CE选点。不能因某条规则在人群差上占优，就直接说它是全部候选里的最佳策略。

完整补充页另列了八项“末轮减未见CE”的事后描述，正负都保留，没有增加p值，也不推荐一律使用末轮。原与新WavLM是不同执行；新WavLM的15/45对照才使用同一长轨迹。原SUBESCO的 δ UAR为-0.3125 pp，按十进制半入规则显示为-0.313。

七、这篇论文贡献了什么，又没有解决什么？

本稿的价值是把一个容易混在一起的问题拆开：验证集得分偏乐观，是一个问题；不同验证规则最后选出的模型，在同一个陌生测试上表现不同，是另一个问题。共享轨迹、共享外测后，后一项差异可以清楚归到**给定资源下的选模程序差别**。第二骨干与配对长窗口进一步说明，只报告说话人是否分开，还遗漏了选模指标和候选轮数。

这不是声纹机制的因果证明。A/B包含不同身份和录音；语料之间还同时改变语言、类数、文本、录音条件和训练预算。数据是演员表演语音，三库此前都被研究过。固定超参数和只微调上层也限制了推广范围。没有HuBERT45或CREMA-D WavLM45，因此没有得到完整的“模型×窗口”矩阵，更不能把一个骨干当作经充分寻优的最强基线。

24条B组对照是整组训练角色交换，不是逐人的孤立因果效应；它的查询录音也参与主A模型的选点。早期DUAL的固定末轮描述已存在验证乐观差，所以整个乐观差不能全归因于选择；它与本稿的人群差仍是不同估计对象。本文没有识别应该把多少说话人分给验证集，没有检验合成语音训练，也没有证明消除了已见 / 未见说话人的性能差距。

后续值得提出的问题包括概率校准、更多骨干与窗口、自然语音上的确认，以及更严格控制身份和录音差异的设计。这些只是未来问题，不是已经完成的结果。对当前读者最可用的建议是：**同时报告验证说话人角色、选模指标、候选轮数，并用真正陌生的外测评价最后选出的模型。**

公开材料包含完整表格、曲线、科学源码和核验摘要。原384次拟合另有预测回放包；新720次的完整逐轮logits和保留权重仍在受控档案。独立CPU复算核对199,780项数值，最大差约 7.1×10^{-15} ；这证明相关数值能复算，不等于独立重训或对所有未来说话人的保证。公开表格回放的范围也小于完整档案核验。

英文稿声明研究自费、无外部资助，作者无利益冲突。研究使用公开演员录音与元数据，没有新招募、新录音或额外个人信息关联；作者说明按TCPS 2相关条款评估该二次使用，未取得机构伦理批准或豁免。Claude协助原始实现、起草和科学审阅；Codex协助设计、实现与执行、文献和数值核查，以及全文、表格和图的起草与修订。AI不是作者，证据审阅和提交批准仍由署名人负责。

公开来源与继续阅读： [英文最终稿](#) • [英文源码](#) • [全部绝对结果及原CSV入口](#) • [公开修订版](#)
• [原384预测包所在历史版本](#)。本文保留原六项与新十项全部主结果，不增加录用概率、AI写作率或新的统计证据。