

语音情感识别中的说话人重叠：外层测试与内层验证划分会怎样影响结果？

作者：Tian Xie

单位：University of Toronto（多伦多大学）

邮箱：tianjack.xie@mail.utoronto.ca

本文是对应英文论文的中文意译与解释，沿用英文稿的章节顺序和证据范围。为便于理解加入类比和术语说明，但不增加实验，也不把原本有限的结论说得更强。所有差值均以 UAR 百分点表示；方括号中的区间，除特别说明外，均为 95% 置信区间。

摘要

语音情感识别模型得分很高，是否就说明它能判断陌生人的情绪？不一定。如果同一个人的录音同时出现在训练集和评估集，模型面对的任务就不同于识别从未见过的说话人。本文把外层测试划分和内层验证划分分开考察，结合一项预先指定的多语料实验和一项执行前冻结的验证乐观偏差检验。

旧研究覆盖三个语料库。三个从零训练模型的平均结果显示，外层、内层都随机划分，相对于两层都按说话人分组，UAR 分别高出 18.24、2.56 和 7.21 个百分点。匹配训练规模的比较还显示，提示句重叠、跨提示句的说话人重叠和重复录音都可能改变分数。

新的 N14R2 实验完成 24 次完整划分、1,920 次训练。在外层测试始终与训练说话人分离的情况下，随机内层验证的“验证乐观偏差”平均多出 1.419 个百分点，区间为 [0.901, 1.937]。这不是说外层测试成绩因此下降了 1.419 点。两项研究的统计单位不同，必须分开解释。

1 引言：高分究竟回答了什么问题？

SER 是 speech emotion recognition，即根据语音识别情绪。许多应用希望模型面对陌生说话人也能工作。但如果把录音逐条随机分配，一个人的部分录音可能用于训练，另一部分用于测试。这时，“熟悉这个人的其他录音”和“完全没见过这个人”被混在了一起。

还有一道常被忽略的边界：验证集。训练过程中，研究者要用它挑选模型参数、选择训练轮次。即使最后的测试集没有说话人重叠，内层验证仍可能存在重叠。因此，必须同时交代模型怎样学习、怎样被选中，以及最后接受什么测试。

本文不提出新分类器，也不声称首次发现这些风险。贡献在于把两道边界系统地组合比较，检查匹配训练规模下的不同重叠条件，并考察部分微调后的预训练模型。

证据分为两层：旧 v2 程序按冻结计划完成 4,943 个实验单元，提供多语料结果；随后进行的 N14R2 在执行前冻结了设计与分析，用新的划分、种子和训练提供主要的超参数选择证据。超参数搜索（HPO）就是比较预先设置的学习率等方案，再用验证集选择。旧 4,943 个单元和新

1,920 次训练不能合并成一个统计样本，也不能被包装成同一套新的执行前方案。以前的 HP0 观察不被当作这次新检验的独立证据。本文用“预先指定”和“执行前冻结”描述方案，不把它们等同于已经核实的公众可见性。

2 实验设计

2.1 数据、指标与模型家族

三个语料都是表演式情绪语音：RAVDESS 有 24 名说话人、8 类情绪；CREMA-D 有 91 名说话人、6 类情绪；SUBESCO 有 20 名说话人、7 类情绪。按冻结的数据清理规则处理重复、标签冲突和不可用文件后，分别保留 1,439、7,435、6,998 条录音。

SUBESCO 的主要比较使用固定的 980 条录音子集：每名说话人、提示句和情绪的组合只保留一次录制，共使用 7 个提示句。因此，这个子集上的主要差值不能简单归因于同一句话的多次录音分散到了训练与测试两侧。

从零训练的模型包括 CNN、ResNet-SE 和 Transformer。它们使用同一冻结前端：22.05 kHz 单声道、30 dB 静音裁剪、64 个 log-mel 频带、128 帧、逐条归一化，以及只作用于训练数据的增强。训练采用类别平衡损失、AdamW 和余弦学习率，最多 100 轮；连续 15 轮没有改善则早停，保留验证损失最低的轮次。

另一组使用冻结的 HuBERT-base、WavLM-base+ 和 wav2vec 2.0-base 表征，只训练线性分类头，可理解为检查预训练特征本身能提供多少分类信息。其特征标准化只使用当前训练部分。旧主要实验进行三次重复，同时改变划分和训练随机性。

UAR 是“各情绪类别召回率的平均值”：先分别计算每类情绪有多少被正确认出，再让各类等权平均。它不同于直接计算全部录音的正确比例。两个 UAR 相减时，本文用“百分点”，不是相对百分比。

旧研究先计算每名说话人的折外 UAR，再平均重复和指定模型家族；N14R2 则对整个验证折或测试折计算六类 UAR。两种汇总方式不能混用。

2.2 外层与内层：RR、RG、GR、GG 是什么？

外层划分决定哪些数据用于最终测试；内层划分把剩余数据分为实际拟合部分和验证部分。外层采用五折，轮流留出一折测试。R 表示分层随机划分，G 表示按说话人分组，使相应边界两侧的说话人分离。

记号	外层测试边界	内层训练 / 验证边界
RR	随机划分	随机划分
RG	随机划分	按说话人分组
GR	按说话人分组	随机划分
GG	按说话人分组	按说话人分组

本文把 RR-GG 称为协议“溢价”：这里的意思是两种完整评估流程的分数差，不是经济意义上的价格。它满足恒等式：

$$RR-GG = (RG-GG) + (RR-RG)$$

前一项是内层已分组时改变外层的差值；后一项是外层仍随机时改变内层的差值。两项相加等于总差值，但这只是协议对照与代数关系，不是证明两种原因各自贡献了多少。分组同时改变了具体训练、验证成员，可能也改变分配数量。GR-GG 则回答外层已经分组时，改变内层会怎样。

2.3 匹配训练规模的重叠比较与部分微调

为进一步区分“认识说话人”和“见过提示句”，实验在 CREMA-D 与 SUBESCO-full 上构造说话人组与提示句组的棋盘式组合。固定一个交叉区域作为测试集，然后形成四种训练条件：

- none：既不包含测试说话人，也不包含测试提示句。
- spk：包含测试说话人说的其他提示句，但不包含测试提示句。
- prm：包含其他人说的测试提示句，但不包含测试说话人。
- both：允许上述两种重叠。

各条件匹配到最小合法训练池的规模，约为 3,440 和 3,359 条拟合录音，并保持类别分层和共同的内层规则。因此不是“多给数据就涨分”的简单比较。测试项的其他版本被排除，只有专门的 SUBESCO sibling-take 条件允许同一组合的重复录音。五个说话人折、两次提示组轮换、两次重复，使每种条件和每个模型各有 20 次训练；模型为 CNN 与 ResNet-SE。这些子采样实验的绝对分数不能直接与主要四格实验比较。

另一项实验在录音总数匹配的前提下，比较五个 24 人 CREMA-D 面板与五个 91 人面板。它同时改变说话人数和每人的录音密度，不能把两者完全拆开归因。

部分微调使用 WavLM-base+，更新顶部四层 Transformer 和线性头。训练采用类别平衡交叉熵损失和 AdamW，编码器和分类头的恒定学习率分别为 5×10^{-5} 和 10^{-3} ，权重衰减为 10^{-2} ，每批 16 条，使用 fp16 半精度；最多训练 15 轮，验证损失连续 3 轮没有改善就早停，保留验证损失最低的轮次。训练时随机截取 3 秒片段，评估时使用录音的前 10 秒。

对照组冻结编码器，但沿用相同头部、划分、种子、开启 dropout 的训练模式，以及相同轮次预算；池化特征不做前述标准化。每个主要语料使用第一套 RR/GG 划分和两个训练种子。这个“同训练制度冻结对照”不是主要实验中的标准化线性探针；完整架构和超参数已固定在仓库保存的实验材料中。

2.4 旧研究怎样做统计？

旧研究比较同一说话人在不同条件下的结果，使用 10,000 次整名说话人重采样产生置信区间，并进行双侧 Wilcoxon 检验，在预定假设家族内做 Holm 多重比较校正。

95% 置信区间体现相应统计方法的长期覆盖性质：反复按同一规则抽样并构造区间，大约 95% 的区间应覆盖目标值。它不是“每个人有 95% 概率获得这个增益”，也不是“真值落在本次区间内的概率就是 95%”。p 值是在相应零假设与统计前提下，出现当前或更极端统计结果的概率；它不是结论出错概率，也不衡量效果是否重要。Holm 校正用于限制同时检验多个问题带来的误报。

SUBESCO 两项重叠比较 N07-N08、微调相对冻结对照的增量 N11-N13，在开跑前就因模拟检验能力偏低被指定为“仅估计”。即使区间不跨零，也不能因此把它们纳入预先指定的假设检验家族。旧区间主要描述已实现训练流程下的说话人差异，不代表跨语料或所有重新训练可能性的完整不确定性。

3 多语料结果

3.1 两道边界都影响报告分数

下表保留主要结果。Scratch 是三个从零训练模型的平均，Probe 是三个冻结编码器探针的平均。单位为 UAR 百分点，方括号是旧研究的说话人 bootstrap 区间；所有列出的预先指定检验均为 Holm 校正后 $p < 0.001$ 。

语料 / 说话人数	Scratch RR-GG	Scratch RG-GG	Scratch RR-RG	Probe RR-GG
RAVDESS 24	18.24 [15.53, 21.06]	12.16 [10.18, 14.21]	6.08 [4.70, 7.41]	11.78 [9.73, 14.15]
CREMA-D 91	2.56 [2.08, 3.06]	1.16 [0.74, 1.59]	1.40 [1.05, 1.75]	2.16 [1.73, 2.64]
SUBESCO-980 20	7.21 [5.15, 9.39]	3.98 [2.29, 5.67]	3.23 [2.22, 4.22]	5.34 [4.02, 6.90]

三个语料的完整协议差值都为正，但大小明显不同。SUBESCO-980 的 7.21 点由 3.98 和 3.23 两项组成；RAVDESS 为 12.16 与 6.08；CREMA-D 为 1.16 与 1.40。不能据此给所有 SER 论文

统一减去一个“纠正分数”，也不能把某种划分在文献中的出现比例乘以这里的差值，推算整个领域夸大了多少。

3.2 控制训练数量后，不同重叠条件仍有差别

匹配条件比较	UAR 差值 [95% CI]	统计地位
CREMA-D: 仅提示句重叠 - none	11.07 [9.82, 12.34]	预先指定的推断检验
CREMA-D: 仅跨提示句说话人重叠 - none	2.68 [1.79, 3.54]	预先指定的推断检验
SUBESCO-full: both+sibling - both	10.09 [7.99, 12.41]	预先指定的推断检验
CREMA-D: 24 人面板溢价 - 匹配的 91 人面板溢价	4.90 [3.95, 5.87]	预先指定的推断检验
SUBESCO-full: 仅提示句重叠 - none	5.27 [2.68, 7.86]	仅估计
SUBESCO-full: 仅说话人重叠 - none	15.89 [13.39, 18.48]	仅估计

前四项均为 Holm $p < 0.001$ 。前三项固定测试成员并匹配训练数量，说明训练集允许哪些类型的重叠仍与结果有关；第四项匹配录音总数，比较不同人数与密度的组合。但控制了数量，不等于控制了所有训练样本属性，更不等于直接看到神经网络使用了“声纹”。

24 人面板的分析涉及五个小面板里出现过的 72 名不同说话人，不是 72 次独立面板抽样。SUBESCO 两项估计的大小排序与 CREMA-D 不同，也不能据此声称某种语言更依赖说话人或提示句：并没有预先指定这样的跨语料检验。

3.3 部分微调之后，协议溢价仍然存在

语料	RR 的 UAR (%)	GG 的 UAR (%)	RR-GG, 百分点 [95% CI]
RAVDESS	78.58	59.57	19.01 [14.78, 23.16]
CREMA-D	70.34	68.58	1.76 [0.85, 2.69]
SUBESCO-980	59.90	53.11	6.79 [3.88, 9.80]

三项均为 Holm $p < 0.001$ ，说明本实验中的协议敏感性并非只有从零训练的模型才有。与同训练制度的冻结对照相比，微调后的协议溢价分别增加 14.17 [8.82, 19.60]、2.61 [1.47, 3.74]、8.57 [5.00, 12.50] 点。这三项增量仍然只是预先指定的估计结果。

还要注意基线偏弱：冻结对照的 60 次训练中，54 次选中最后一轮，绝对 UAR 也较低。这提示共同预算可能限制了对照的表现。因此，可以说部分微调后仍观察到溢价，不能进一步说“微调必然增强泄漏”。

4 新实验：检验验证乐观偏差

4.1 N14R2 的设计与统计单位

N14R2 问的是一个更窄的问题：外层测试完全相同且说话人分离时，随机内层验证是否比按说话人分组更高估被选中模型的测试成绩？旧 v2 的 HP0 结果只是历史背景。中间曾有 N14R 因基础设施事故而未完成；其中 16 个完整 draw，以及包含部分 draw 的全部 1,298 次成功训练，都被排除。N14R2 不使用旧预测、权重、划分或训练种子。

draw 可理解为“按预定随机规则完整重新分一次考场”。每个 draw 包含五个外层折，而不是一个人。执行前冻结的规范固定 24 个主要 draw 和 4 个备用 draw；本次备用没有启用。每个 draw 的五折外层测试由 GR、GG 共用，始终按说话人分组。内层验证比例为 25%，GR 按样本随机，GG 按说话人分组，并要求六类情绪都出现；两者的实际录音数量不必完全相同。

N14R2 复用冻结的 log-mel 声学前端、ResNet-SE 模型架构、训练数据增强、类别平衡损失、AdamW 和余弦学习率调度。八种配置组合两个学习率（0.0003、0.001）、两个权重衰减（0.0001、0.001）与两个 dropout 比例（0.1、0.3）。每个 draw / 折只有一个训练重复，各配置和两种条件配对使用训练种子。批量为 64，最多 100 轮，早停耐心为 15。每次训练先按最低验证损失选轮次；随后在每个 draw、每个折、每个 GR 或 GG 条件内，分别按该完整验证折的最高 UAR 从八种配置中选模型，而不是汇总多个折后统一选配置。完全并列时选预定编号较小的配置。

用考试作类比：V 是用来挑选备考方案的模拟考成绩，T 是方案选定后的正式考试成绩。V-T 表示模拟考比正式考乐观多少。这里只是帮助理解：GR 的正式考试同样没有训练说话人，因此不能把 GR 说成正式考试泄露了考生。

每个 draw 先把五折的 $(V-T)_{GR} - (V-T)_{GG}$ 等权平均，再对 24 个 draw 等权平均。于是统计单位是 24 次完整划分，不是 24 个人；120 个折和 1,920 次训练也不是独立重复样本。

主要检验是 24 个 draw 差值的双侧单样本 t 检验，自由度 23，使用 95% t 区间。它属于独立的单成员 Holm 家族，所以调整前后 p 值相同。正向支持要求均值为正且 $p \leq 0.05$ 。另有 100,000 次 draw bootstrap 和全部 2^{24} 种符号翻转敏感性分析；符号翻转还需要对称性 / 符号可交换性，不能不加条件地称为万能精确检验。

4.2 结果，以及为什么要保留一个报表错误？

所有 24 个主要 draw、1,920 次训练都完成，没有失败、重试或备用启用。完整性经哈希绑定并锁定后才评分。主要结果如下：

项目	结果
平均验证乐观偏差增量	+1.419 个百分点
95% Student-t 区间	[0.901, 1.937]
draw 差值标准差 / 均值标准误	1.226 / 0.250 个百分点
t 值与自由度	t(23)=5.669
双侧 p / Holm p	9.013×10^{-6}
draw bootstrap 区间	[0.950, 1.906]
符号翻转敏感性 p	4.768×10^{-6}

标准差描述不同 draw 的差值波动；标准误描述均值估计的不确定程度。敏感性分析与主要结果方向一致，但没有替代执行前冻结的主要检验。

另一个描述量 D09R2 比较：通过 HP0 选配置后，GR-GG 的外层测试差值，相对于固定配置时改变多少。固定配置是学习率 0.001、权重衰减 0.0001、dropout 0.1。该变化为 -0.076 点，95% t 区间 [-0.320, 0.169]，不作正式假设检验判定。因此，本实验支持“验证更乐观”，而非“测试损失 1.419 点”；D09R2 也不证明没有损害或两者等效。

评分后的原始 JSON 曾在独立验证中失败。原因不是科学结果不一致，而是一个输出字段：总计划应为 28 个 draw，即 24 个主要加 4 个备用，评分器却写成了 24。原输出和失败报告完整保留；另建明确标注的修正版，只把该整数 24 改成 28，实际仅改变一个字节。科学数值、源码、计划和分析锁均未改动。

未经修改的冻结验证器随后重新完整重建，并验证修正版零差异通过。这应如实称为“有记录并在稿件中披露的元数据勘误”，不能写成原始评分文件从未出错。

5 讨论、限制与可复现性

整体证据说明，报告分数受外层和内层两道边界影响；匹配暴露条件进一步区分了几类重叠。若验证集的用途是估计陌生说话人的表现，就应采用与该目标相符的说话人分离验证，并明确报告两层划分。但这些结果不提供通用数值修正，也没有识别出唯一因果机制。

研究范围限于表演式语料、冻结实现和预先指定的随机化。旧研究的说话人区间与 N14R2 的 draw 区间描述不同波动，不能合并。微调增量受弱冻结基线限制。N14R2 前瞻部署在四台 RTX 4090 主机上，配对条件与配置位于同一主机，但驱动和主机差异并未消除。它的目标仍然以固定语料、流程和部署为条件，不自动推广到任意新说话人、语言或数据集。

仓库保存了旧研究的冻结计划记录和验证，以及 N14R2 的规范、原始失败、修正版、独立复核与重放说明。冻结的 N14R2 规范要求执行前有公众可访问的回执，但稿件编写时可用的证据未

能核实该回执在执行前确实向公众开放。因此，本文称 N14R2 为“执行前冻结”，而不是“公开预注册”。这是可核实来源与时间记录的限制，不反过来证明仓库在执行当时必定为私有。稿件编写时，SER 仓库确为私有，材料目前访问受限。

旧 v2 验证记录包含 1,320 个核验项，零失败。N14R2 的重放是从保存输出重建分析，不是包含原始音频的一键重训包。其独立验证器如实记录外部特征缓存字节验证为 false：不可变锁中的 Windows 路径在 Linux 重放主机不存在。实际云端缓存另经操作者的 PINS 检查，但两者不能冒充同一种验证。

原始音频和特征缓存不重新分发；本轮论文修订不改变任何冻结实验产物。

6 结论

评估流程要作为整体说明，不能只写最后测试集是否按说话人分开。多语料实验显示两道边界都有协议差值，部分微调后也仍有正溢价。新的 24-draw 实验发现随机内层验证多出 1.419 点乐观偏差，但描述性外测比较没有证明性能损害。

实用原则是：先说明模型要面对谁，再报告训练、验证和测试怎样划分，并始终区分“验证分数显得更好”与“外部预测能力真的更好”。

7 致谢与 AI 使用披露

Anthropic Claude 协助了旧实验实现和最初稿件。OpenAI Codex 协助设计审查、N14R2 的实现与执行、分析验证，以及全部章节和表格的起草修订。这些系统不是作者；署名人类作者负责审阅证据并批准投稿。实验没有新招募参与者或收集新的参与者数据。

实验材料与冻结计划记录保存在 SER 项目仓库（稿件编写时访问受限）。历史标签原样保留：旧方案 SER26-prereg-1，N14R2 方案 SER26-N14R2-prereg-1，完成结果及勘误 SER26-N14R2-complete-20260906。这些历史标签的名称不是执行前公众可见性的证据。仓库当前为私有，提供此链接不表示材料可供公众访问，也不证明执行前曾公开或当时必为私有。相关文献与英文正式参考文献表对应。